

Table 1: SATD detection performance of Flan-T5 series open-source LLMs in detecting SATD in test code across 0-, 2-, and 4-shot settings. Metrics reported include Precision (P), Recall (R), F1-score (F1), and Support (S) for each model-prompt combination. Keyword-based prompts (e.g., MAT, Jitterbug, Ours) generally yield higher F1-scores, while smaller models and No Keyword/GPT-4 suggested prompts often fail to detect SATD. The best score for each metric is bolded for both the Original and Deduplicated datasets.

Dataset	Prompt	Model	0-shot			2-shots			4-shots			S
			P	R	F1	P	R	F1	P	R	F1	
Original	Ours	T5-SMALL	0.00	0.02	0.01	0.00	0.00	0.00	0.00	0.00	0.00	137
		T5-BASE	0.01	0.31	0.02	0.02	0.51	0.03	0.01	0.45	0.03	
		T5-LARGE	0.03	0.96	0.05	0.04	0.91	0.07	0.04	0.74	0.07	
		T5-XL	0.29	0.86	0.43	0.38	0.79	0.51	0.47	0.64	0.54	
		T5-XXL	0.10	0.98	0.18	0.12	0.96	0.21	0.11	0.95	0.20	
	No Keyword	T5-SMALL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-BASE	0.00	0.03	0.01	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-LARGE	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XL	0.33	0.01	0.01	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XXL	0.10	0.66	0.18	0.19	0.50	0.28	0.17	0.50	0.25	
	GPT 4	T5-SMALL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-BASE	0.01	0.04	0.01	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-LARGE	0.24	0.04	0.06	0.29	0.01	0.03	0.67	0.01	0.03	
		T5-XL	1.00	0.04	0.07	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XXL	0.20	0.87	0.32	0.18	0.82	0.30	0.18	0.80	0.30	
	Jitterbug	T5-SMALL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-BASE	0.00	0.03	0.01	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-LARGE	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XL	1.00	0.47	0.64	1.00	0.11	0.20	1.00	0.08	0.15	
		T5-XXL	0.28	0.83	0.42	0.27	0.82	0.41	0.30	0.80	0.43	
	MAT	T5-SMALL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-BASE	0.00	0.04	0.01	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-LARGE	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XL	0.99	0.52	0.68	1.00	0.13	0.23	1.00	0.12	0.21	
		T5-XXL	0.33	0.80	0.47	0.40	0.78	0.53	0.42	0.74	0.54	
Deduplicate	Ours	T5-SMALL	0.01	0.03	0.01	0.00	0.00	0.00	0.00	0.00	0.00	113
		T5-BASE	0.02	0.36	0.04	0.02	0.55	0.04	0.02	0.52	0.04	
		T5-LARGE	0.03	0.95	0.05	0.04	0.89	0.08	0.05	0.76	0.09	
		T5-XL	0.26	0.85	0.40	0.36	0.76	0.49	0.46	0.65	0.54	
		T5-XXL	0.10	0.97	0.18	0.11	0.97	0.20	0.11	0.96	0.20	
	No Keyword	T5-SMALL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-BASE	0.01	0.04	0.02	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-LARGE	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XXL	0.11	0.74	0.20	0.22	0.58	0.32	0.21	0.57	0.31	
	GPT 4	T5-SMALL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-BASE	0.01	0.04	0.02	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-LARGE	0.25	0.04	0.07	0.29	0.02	0.03	0.67	0.02	0.03	
		T5-XL	1.00	0.04	0.07	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XXL	0.19	0.87	0.31	0.18	0.87	0.29	0.18	0.83	0.30	
	Jitterbug	T5-SMALL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-BASE	0.01	0.02	0.01	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-LARGE	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XL	1.00	0.40 ¹	0.57	1.00	0.12	0.22	1.00	0.09	0.16	
		T5-XXL	0.28	0.82	0.42	0.26	0.81	0.39	0.28	0.79	0.41	
	MAT	T5-SMALL	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-BASE	0.01	0.03	0.01	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-LARGE	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	
		T5-XL	1.00	0.46	0.63	1.00	0.15	0.26	1.00	0.13	0.23	
		T5-XXL	0.34	0.79	0.47	0.40	0.76	0.52	0.40	0.72	0.52	